TC01 – Entrega #2: Algoritmo de Solução com NeuroLKH para o TSP Biobjetivo de 250 Cidades

Cláudio Márcio Campos Paixão
Filipe Carvalho de Andrade
Matheus Amarante Carvalho
Matheus Cascalho dos Santos

Professor: Prof. Dr. Lucas S. Batista
EEE910A – Otimização Multiobjetivo
Programa de Pós-Graduação em Engenharia Elétrica (PPGEE)
Universidade Federal de Minas Gerais (UFMG)

UFMG



Roteiro da Apresentação

1. O Que Será Otimizado: Problema e Modelagem
2. Escolha e Justificativa: Meta-Heurística NeuroLKH
3. Adaptação do Problema e Execução no NeuroLKH
4. Protocolo Experimental e Próximos Passos
5. Referências

O Que Será Otimizado?

Definição do Problema do Caixeiro Viajante Biobjetivo ($n = 250$ Cidades)

Estrutura da Rota (Decisão)

- **250 Cidades:** Grafo completo dirigido $G = (V, A)$ com origem fixa na cidade 1.
- **Total de Arcos:** $250 \times 249 = 62.250$ conexões possíveis.
- **Espaço de Busca:** $249! \approx 1,29 \times 10^{490}$ rotas possíveis (inviável por força bruta).

Objetivos Conflitantes (Metas)

- **Objetivo 1 – Tempo Total (f_1):** Minimizar o tempo em horas (`tempo.csv`, **assimétrico**: $t_{ij} \neq t_{ji}$).
- **Objetivo 2 – Distância Total (f_2):** Minimizar a distância em km (`distancia.csv`, **simétrica**: $d_{ij} = d_{ji}$).

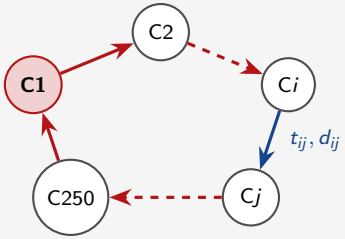
Síntese do Conflito Multiobjetivo

Rotas mais curtas em quilômetros utilizam vias mais lentas, enquanto rotas mais rápidas exigem desvios mais longos. O objetivo é obter a **Fronteira de Pareto** com as rotas de melhor compromisso.

Desenho do Problema: Do Grafo à Fronteira de Pareto

Mapeamento entre a Escolha da Rota (Espaço de Decisão) e os Custos (Espaço de Objetivos)

1. Espaço de Decisão (Rota)

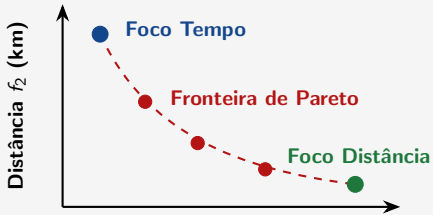


Ciclo Hamiltoniano Único ($x_{ij} \in \{0, 1\}$)

NeuroLKH

Otimiza

2. Espaço de Objetivos (Pareto)



Modelagem Matemática do Problema

Formulação Inteira Mista (MILP) que Define as Regras do Solucionador

Variáveis de Decisão

Binárias de Roteamento:

$$x_{ij} \in \{0,1\}, \quad \forall (i,j) \in A$$

Indica se o arco dirigido de i para j faz parte da rota ($x_{ij} = 1$) ou não ($x_{ij} = 0$).

Contínuas de Ordem (MTZ):

$$1 \leq u_i \leq 249, \quad \forall i \in V \setminus \{1\}$$

Garante ciclo único sem subciclos desconectados.

Modelo Biobjetivo Completo

$$\min f_1(x) = \sum_{(i,j)\in A} t_{ij} x_{ij} \quad \text{(Tempo)}$$

$$\min f_2(x) = \sum_{(i,j)\in A} d_{ij} x_{ij} \quad \text{(Distância)}$$

$$\text{s.a.} \sum_{j \neq i} x_{ij} = 1, \quad \forall i \in V$$

$$\sum_{i \neq j} x_{ij} = 1, \quad \forall j \in V$$

$$u_i - u_j + 249 x_{ij} \leq 248, \ \forall i \neq j \in V \setminus \{1\}$$

O Que é o Algoritmo NeuroLKH?

Entrega #2 – Item ii(a): Combinação de Busca Local LKH com Aprendizado Profundo

Essência do Método

- **Fusão Híbrida:** Rede Neural (**SGN**) + Heurística **LKH**.
- **Sem Regras Manuais:** Substitui cálculos lentos por predição direta.
- **Foco Inteligente:** Avalia apenas ~ 20 arestas promissoras por cidade.
- **Ideal para $n = 250$:** Converge em poucos *trials*, viabilizando toda a Fronteira de Pareto.

LKH Clássico (Tradicional)

Regras fixas (α-nearness) $\rightarrow$ Busca lenta
Exige milhares de *trials*

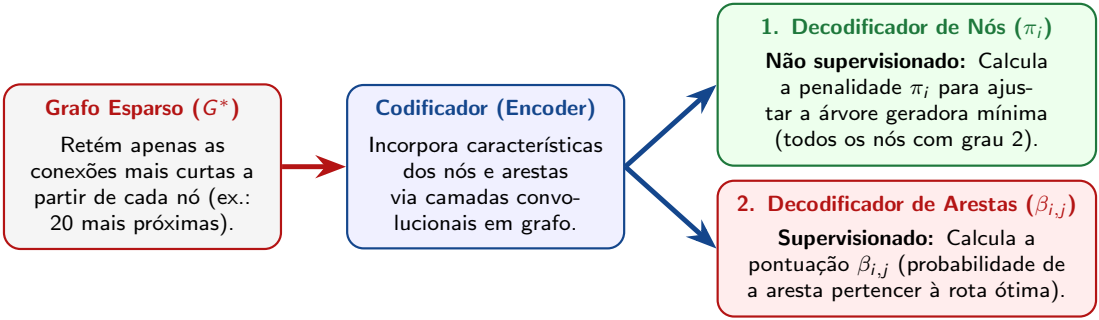
Aprendizado Profundo (SGN)

NeuroLKH (Nossa Escolha)

Pesos π_i + Probabilidades $\beta_{i,j}$ via IA
Rota ótima com 10$\times$ menos trials

Arquitetura da Rede Neural (SGN) no NeuroLKH

Codificador Convolucional e Duplo Decodificador Paralelo (Nós e Arestas)



Sinergia dos Decodificadores Paralelos

Enquanto π_i remodela matematicamente os custos para facilitar a busca, $\beta_{i,j}$ ranqueia diretamente quais conexões merecem ser testadas pela heurística LKH.

Adaptação ao Nosso Problema: Escalarização e Assimetria

Como Transformamos Tempo ($t_{i,j}$) e Distância ($d_{i,j}$) na Entrada do NeuroLKH

1. Distância Original Escalarizada ($s_{i,j}$)

Normalizamos Tempo e Distância para $[0, 1]$ e definimos subproblemas variando o peso $w \in [0, 1]$:

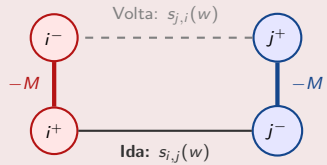
$$s_{i,j}(w) = w \cdot \tilde{t}_{i,j} + (1 - w) \cdot \tilde{d}_{i,j}$$

Em seguida, o NeuroLKH aplica as penalidades π_i da rede:

$$c_{i,j}(w) = s_{i,j}(w) + \pi_i + \pi_j$$

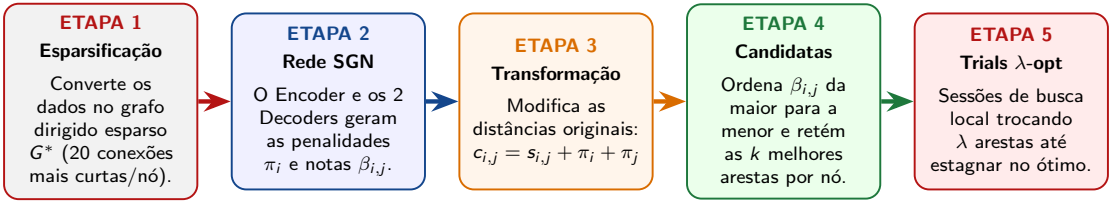
2. Simetrização ($2n$ Nós – Jonker-Volgenant)

Como $t_{i,j} \neq t_{j,i}$, desdobramos cada cidade i em entrada (i^-) e saída (i^+) antes das trocas λ-opt:



Aplicação do Algoritmo NeuroLKH

As 5 Etapas Estruturadas de Execução do Método

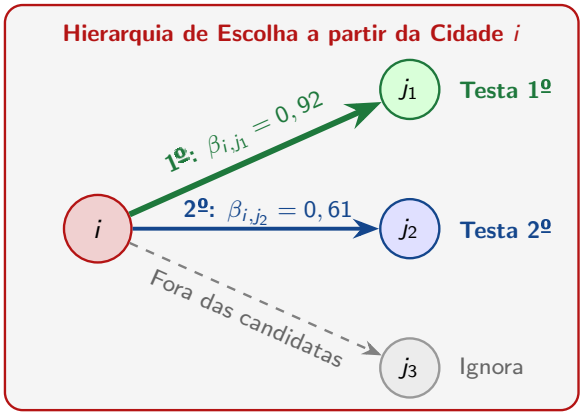


Propriedade da Transformação de Distâncias ($c_{i,j} = s_{i,j} + \pi_i + \pi_j$)

Como qualquer rota válida visita todos os nós exatamente uma vez, somar $\pi_i + \pi_j$ adiciona uma constante $2\sum_{i=1}^{n} \pi_i$ ao custo total do ciclo. Isso **guia a busca local de forma mais eficiente sem alterar a rota ótima original**.

Como os Pontos (Arestas) São Escolhidos para a Rota?

Seleção Guiada por Probabilidade ($\beta_{i,j}$) Durante as Trocas λ-opt

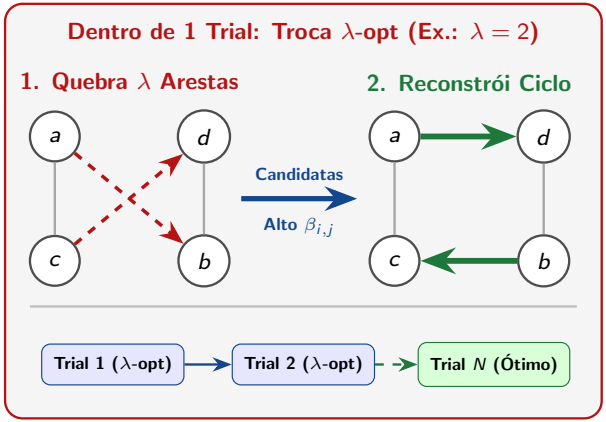


Regras de Seleção nas Trocas λ-opt

- **1. Restrição de Movimentos:** Testa apenas arestas do conjunto candidato (k melhores).
- **2. Prioridade por Nota $\beta_{i,j}$:** Segue a ordem da maior probabilidade prevista pela SGN.
- **3. Direcionamento Ativo:** Conecta primeiro as arestas de topo e ignora conexões ruins.

Como Funcionam os *Trials* e a Troca λ-opt na Prática?

Mecânica de "Quebra e Reconstrução" da Rota nas Sessões de Busca



Dinâmica de Busca

- **Mecanismo λ-opt:**
  "Quebra" λ conexões atuais (vermelho) e reconstrói o ciclo com arestas candidatas da IA (verde).
- **O que é 1 Trial?**
  Parte de uma rota inicial e aplica trocas λ-opt seguidas até não haver mais redução de custo.
- **Sessões de Trials:**
  Novos *trials* aplicam perturbações na rota para escapar de mínimos locais e alimentar o Arquivo de Pareto.

Construção da Fronteira de Pareto e Protocolo Experimental

Coleta das Soluções Não-Dominadas e Planejamento para a Entrega #3

Entrega	Etapa	Escopo Desenvolvido
#1	Modelagem	Caracterização dos dados ($n = 250$) e formulação MILP biobjetiva
#2	Algoritmo	Escolha, justificativa e procedimento com o **NeuroLKH**
#3	Resultados	Execução multiobjetivo, métricas (Δ, Hipervolume) e decisão AHP

Arquivo de Pareto e Avaliações

- Cada rota gerada nos *trials* λ-opt para diferentes pesos w passa pelo filtro de dominância de Pareto.
- **5 Execuções Independentes** com **10 pontos de avaliação** cada (Δ e Hipervolume).

Tomada de Decisão (AHP)

- Seleção da rota de compromisso final na Fronteira de Pareto considerando **4 atributos**: Tempo total, Distância total, Maior trecho individual e Velocidade média.

Referências Bibliográficas

- **APPLEGATE, D. L.; BIXBY, R. E.; CHVÁTAL, V.; COOK, W. J.** *The traveling salesman problem: a computational study*. Princeton: Princeton University Press, 2007.
- **BATISTA, L. S.** *Otimização multiobjetivo: relações de dominância e trabalho computacional*. Belo Horizonte: UFMG, 2026. Notas de aula da disciplina EEE910A, PPGEE.
- **HELSGAUN, K.** An effective implementation of the Lin-Kernighan traveling salesman heuristic. *European Journal of Operational Research*, v. 126, n. 1, p. 106–130, 2000.
- **JONKER, R.; VOLGENANT, T.** Transforming asymmetric into symmetric traveling salesman problems. *Operations Research Letters*, v. 2, n. 4, p. 161–163, 1983.
- **MILLER, C. E.; TUCKER, A. W.; ZEMLIN, R. A.** Integer programming formulation of traveling salesman problems. *Journal of the ACM*, v. 7, n. 4, p. 326–329, 1960.
- **XIN, L.; SONG, W.; CAO, Z.; ZHANG, J.** NeuroLKH: Combining deep learning model with Lin-Kernighan-Helsgaun heuristic for solving the traveling salesman problem. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 34, p. 7472–7483, 2021.

TC02 – Entrega #2: Método ε-restrito com Enumeração Discreta

Seleção Multiobjetivo de Áreas para Implantação Fotovoltaica

Cláudio Márcio Campos Paixão
Filipe Carvalho de Andrade
Matheus Amarante Carvalho
Matheus Cascalho dos Santos

Professor: Prof. Dr. Lucas S. Batista
EEE910A – Otimização Multiobjetivo
Programa de Pós-Graduação em Engenharia Elétrica (PPGEE)
Universidade Federal de Minas Gerais (UFMG)

UFMG



Roteiro da Apresentação

Entrega #2 – Modelagem e escolha da ferramenta de otimização

1. O Problema e a Modelagem
2. Método ε-restrito
3. Enumeração, Simulador e Fronteira de Pareto
4. Justificativa, Validação e Referências

O Que Será Otimizado?

Seleção de regiões com maior aproveitamento e menor dificuldade topográfica

Objetivo 1 — Maior Área Utilizável

Maximizar $A_{\text{útil}}(x)$

- Somar as áreas projetadas dos triângulos aceitos.
- Contabilizar somente componentes contíguas com área $\geq A_{\min}$.
- Potência estimada proporcional à área (sem layout de mesas).

Objetivo 2 — Menor Declividade

Minimizar $\theta_{\text{RMS}}(x)$

- Penalizar regiões com inclinações elevadas.
- Ponderar o cálculo pela área de cada triângulo.
- Representar facilidade topográfica de implantação.

Conflito Multiobjetivo

Aumentar a área selecionada pode exigir aceitar regiões mais inclinadas; queremos o melhor compromisso.

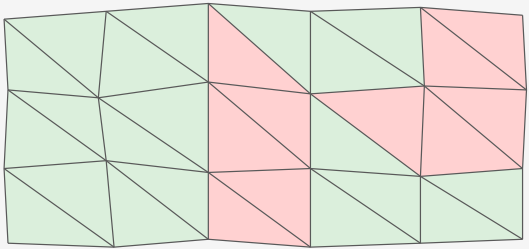
Representação Topográfica do Terreno

Dados RTK ou curvas de nível → TIN → métricas locais e conectividade

Dados e Pré-processamento

- **Superfície 2,5D** com coordenadas (x, y, z).
- **Triangulação e recorte** no perímetro de estudo.
- **Para cada face i:** área A_i, declividade θ_i e descontinuidade η_i.
- **Adjacência** entre faces por aresta compartilhada.

Exemplo de malha triangular



Potencialmente utilizável

Área mais restritiva

A geometria detalhada de mesas, sombreamento e terraplenagem permanece fora do escopo.

Modelagem Matemática do Problema

Duas variáveis de decisão, critérios de seleção e funções objetivo

Variáveis e Restrições

$x = (\theta_{\max}, \eta_{\max})$

- $\theta_{\max}$: declividade máxima admissível
- $\eta_{\max}$: descontinuidade angular máxima

Triângulo i aceito se: $\theta_i \leq \theta_{\max}$ **e** $\eta_i \leq \eta_{\max}$

Remover componentes conexas com área inferior a $A_{\min}$.

Objetivos e Compromisso

Objetivo 1 — maximizar área útil

$$A_{\text{útil}}(x) = \sum_{i \in S(x)} A_i$$

Objetivo 2 — minimizar declividade RMS

$$\theta_{\text{RMS}}(x) = \sqrt{\left(\sum_{i \in S(x)} A_i \cdot \theta_i^2\right) / \sum_{i \in S(x)} A_i}$$

As somas consideram os triângulos selecionados após os filtros de conectividade.

Representação 2,5D e TIN fixas: somente os dois limiares topográficos são otimizados.

Método ε-restrito: Como Funciona?

Otimizar um objetivo e transformar o outro em uma restrição explícita

Formulação Multiobjetivo Original

$$\max \; A_{\text{útil}}(x)$$
$$\min \; \theta_{\text{RMS}}(x)$$

Dois objetivos conflitantes, sem uma única melhor resposta para todas as preferências.



Subproblema ε-restrito

$$\min \quad \theta_{\text{RMS}}(x)$$
$$\textbf{sujeito a: } A_{\text{útil}}(x) \geq \varepsilon$$

ε: área mínima exigida (ha).
Variar ε produz diferentes compromissos.

ε não é peso nem variável de decisão: é uma exigência de área definida em cada subproblema.

Exemplo Ilustrativo do Método ε-restrito

Uma exigência maior de área pode alterar a solução de menor declividade

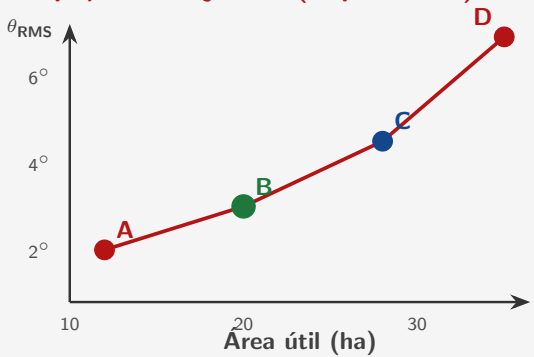
Alternativas Topográficas Hipotéticas

Solução	Área útil	θ_{RMS}
A	12 ha	$2,0^\circ$
B	20 **ha**	$3,0^\circ$
C	28 ha	$4,5^\circ$
D	35 ha	$7,0^\circ$

$\varepsilon = 18$ **ha** $\rightarrow$ **B** (20 **ha**; $3,0^\circ$)

$\varepsilon = 25$ **ha** $\rightarrow$ **C** (28 **ha**; $4,5^\circ$)

Espaço dos objetivos (esquemático)

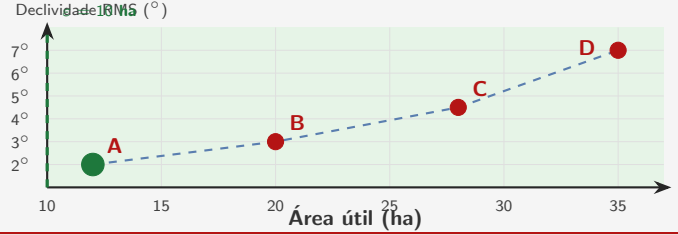


Simulador Interativo — Método ε-restrito

Escolha a área mínima ε e observe a alternativa admissível de menor declividade RMS

10 ha | 18 ha | 25 ha | 32 ha | 36 ha

Espaço dos objetivos



Resultado do ε-restrito

Solução A

12 ha • 2,0° RMS

4 alternativa(s) satisfaz(em) $A_{\text{útil}} \geq 10$ ha.

Escolhida a admissível de menor declividade RMS.

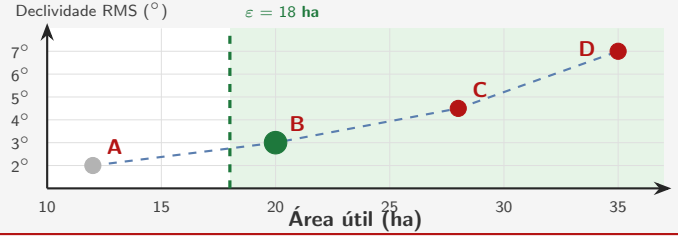
Simulação didática com quatro configurações hipotéticas — não utiliza resultados reais da TIN.

Simulador Interativo — Método ε-restrito

Escolha a área mínima ε e observe a alternativa admissível de menor declividade RMS

10 ha | **18 ha** | 25 ha | 32 ha | 36 ha

Espaço dos objetivos



Resultado do ε-restrito

Solução B

20 ha • 3,0° RMS

3 alternativa(s) satisfaz(em) $A_{\text{útil}} \geq 18$ ha.

Escolhida a admissível de menor declividade RMS.

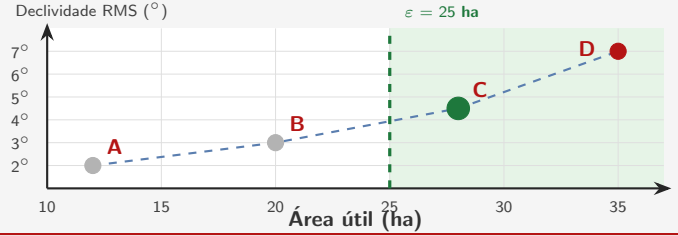
Simulação didática com quatro configurações hipotéticas — não utiliza resultados reais da TIN.

Simulador Interativo — Método ε-restrito

Escolha a área mínima ε e observe a alternativa admissível de menor declividade RMS

10 ha | **18 ha** | **25 ha** | **32 ha** | **36 ha**

Espaço dos objetivos



Resultado do ε-restrito

Solução C

28 ha • 4,5° RMS

2 alternativa(s) satisfaz(em) $A_{\text{útil}} \geq 25$ ha.

Escolhida a admissível de menor declividade RMS.

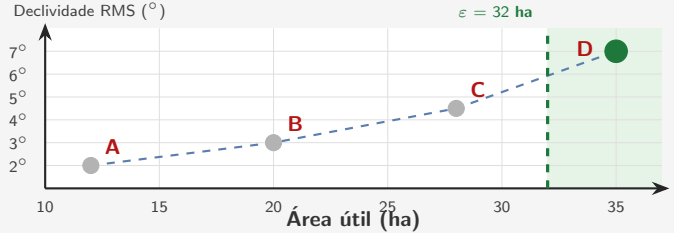
Simulação didática com quatro configurações hipotéticas — não utiliza resultados reais da TIN.

Simulador Interativo — Método ε-restrito

Escolha a área mínima ε e observe a alternativa admissível de menor declividade RMS

10 ha | 18 ha | 25 ha | **32 ha** | 36 ha

Espaço dos objetivos



Resultado do ε-restrito

Solução D

35 ha • 7,0° RMS

1 alternativa(s) satisfaz(em) $A_{\text{útil}} \geq 32$ ha.

Escolhida a admissível de menor declividade RMS.

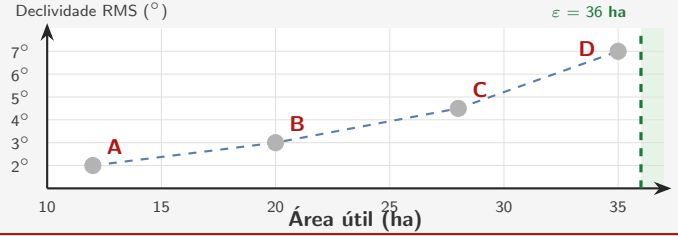
Simulação didática com quatro configurações hipotéticas — não utiliza resultados reais da TIN.

Simulador Interativo — Método ε-restrito

Escolha a área mínima ε e observe a alternativa admissível de menor declividade RMS

10 ha | 18 ha | 25 ha | 32 ha | **36 ha**

Espaço dos objetivos



Resultado do ε-restrito

Inviável

Nenhuma alternativa possui área $\geq$ 36 ha.

É preciso reduzir ε ou ampliar as alternativas avaliadas.

Simulação didática com quatro configurações hipotéticas — não utiliza resultados reais da TIN.

Aplicação Computacional do Algoritmo

Pipeline proposto: pré-processamento, enumeração, avaliação e seleção Pareto



Como aplicar ε com reutilização de cálculos

Armazenar as configurações avaliadas e reutilizar a tabela de objetivos para diferentes áreas mínimas ε.

Por Que Escolher o Método ε-restrito?

Justificativa conceitual e comparação com métodos alternativos

Vantagens para Nosso Problema

- Método escalar formalmente estudado na disciplina.
- ε representa área mínima: significado físico direto.
- Pode recuperar pontos Pareto não suportados, inclusive em fronteiras não convexas.
- A enumeração aproveita o pequeno número de variáveis de decisão.

Alternativas e Limitações

- **Soma ponderada:** Simples, mas pode perder soluções não suportadas.
- **NSGA-II e MOEA/D:** Aproximativos e úteis em espaços grandes; não garantem a fronteira exata.
- **Limitação do ε-restrito:** Precisa resolver vários subproblemas e lidar com empates / soluções fracamente eficientes.

Nosso algoritmo principal: método ε-restrito; ferramenta de resolução: enumeração de limiares.

Exatidão e Custo Computacional

A garantia de otimalidade depende da cobertura dos limiares e da malha adotada

Quando a Fronteira é Exata?

- Enumeração completa dos limiares críticos distintos de θ_i e η_i.
- Resolver os níveis relevantes de ε e aplicar filtragem por dominância.
- Exatidão relativa à TIN fixa e ao modelo simplificado — não ao layout FV real.
- Uma grade reduzida produz exatidão apenas dentro da grade.

Custo Esperado

$K = K_\theta \times K_\eta$

K = quantidade de combinações de limiares testadas.

Avaliação direta: $\mathcal{O}(K \times N)$

N = número de triângulos da TIN.

Exemplo ilustrativo: grade $25 \times 25 \rightarrow 625$ avaliações;

NSGA-II com 100 indivíduos $\times 100$ gerações $\rightarrow \sim$ 10 mil.

A comparação de tempo real deve medir número de avaliações e segundos de execução nos mesmos dados.

Construção da Fronteira e Protocolo Experimental

Planejamento da entrega #3: resultados, indicadores e escolha multicritério

Entrega	Etapa	Escopo Desenvolvido
#1	Modelagem	TIN, variáveis $\theta_{\max}/\eta_{\max}$, objetivos e restrições
#2	Algoritmo	ε-restrito, enumeração discreta e justificativa
#3	Resultados	Fronteira Pareto, mapas das regiões e análise de desempenho

Validação e Indicadores

- Superfícies sintéticas e levantamento RTK real.
- Indicadores Δ e hipervolume (*s-metric*).
- Comparar custo e cobertura da fronteira obtida.

Tomada de Decisão

- Selecionar até 20 soluções não dominadas.
- Considerar ao menos quatro atributos distintos.
- Definir pesos via AHP e aplicar método multicritério.

Referências Bibliográficas

Fontes utilizadas na formulação e na comparação de métodos

- **BATISTA, L. S.** *Otimização multiobjetivo: métodos escalares*. Belo Horizonte: UFMG, 2026. Notas de aula da EEE910A, PPGEE.
- **BATISTA, L. S.** *Otimização multiobjetivo: relações de dominância*. Belo Horizonte: UFMG, 2026. Notas de aula da EEE910A, PPGEE.
- **TAKAHASHI, R. H. C.** *Otimização escalar e vetorial. Volume 3: Otimização Vetorial*. Belo Horizonte: UFMG, 2007.
- **CHANKONG, V.; HAIMES, Y. Y.** *Multiobjective decision making: theory and methodology*. Mineola: Dover Publications, 2008.
- **DEB, K. et al.** A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, v. 6, n. 2, p. 182–197, 2002.
- **ZHANG, Q.; LI, H.** MOEA/D: A multiobjective evolutionary algorithm based on decomposition. *IEEE Transactions on Evolutionary Computation*, v. 11, n. 6, p. 712–731, 2007.